

# RAG

## (Retrieval Augmented Generation)

Подготовили: Наумович Л., Цителадзе Г., Липинский Л.

# План

- 1) Что это и зачем нужно?
- 2) Схема RAG
- 3) Векторизация
- 4) Поиск в RAG
- 5) Демонстрация
- 6) Возможные улучшения и итоги

Вход: произвольный вопрос

Выход: ответ на вопрос



какой курс доллара к рублю сегодня?



К сожалению, у меня нет доступа к актуальным данным в реальном времени, включая текущий курс доллара к рублю. Для получения свежей информации рекомендуется посетить финансовые сайты, такие как:

ЦБРФ

Investing.com

Yahoo Finance

или использовать приложение банка или финансового сервиса.

# Проблемы

Требуется ответ строго по релевантным данным, но:

- 1) LLM не знает актуальных данных и отказывается отвечать
- 2) Модель придумывает факты

# Возможное решение

SFT (Дообучение модели)

Проблема:

Очень дорого, время затратно, возможно “катастрофическое забывание”, невозможность решения задачи в случае быстроменяющихся данных

**Вход: произвольный вопрос, релевантная внешняя информация**

**Выход: ответ на вопрос на основе внешней информации**

👤 какой курс доллара к рублю сегодня?


Результат поиска: Центральный банк Российской Федерации установил на сегодня следующие курсы иностранных валют к рублю Российской Федерации без обязательств Банка России покупать или продавать указанные валюты по данному курсу код Букв. Единиц код СВ код Курс код Руб CNY, 1¥ 11,3561₽ USD, 1\$ 81,2257₽ EUR, 1€ 93,8365₽

👉 На сегодня курс доллара США (USD) к российскому рублю (₽) составляет **81,2257 ₽** за 1 доллар.

# Что такое RAG?


Это подход, который позволяет LLM использовать внешние данные в реальном времени. Модель не фантазирует, а подтягивает факты из базы знаний и генерирует ответ уже на основе найденной информации.

# Типовая схема RAG:



# Векторизация данных


Embedding модель  
(BERT/Sentence Encoder,  
TF-IDF, BM25)



# Поиск в RAG

В RAG используется векторное представление фрагментов документов из базы знаний

$$q \in \mathbb{R}^n$$



$$d_i \in \mathbb{R}^n$$


$$\text{sim}(q, d_i) = \frac{q \cdot d_i}{\|q\| \|d_i\|}$$

$$(q, d_i) = \sqrt{\|q - d_i\|}$$

# Поиск в векторных базах данных

$$\operatorname{argmin}_{d_i \in \mathcal{C}(q)} [1 - \text{sim}(q, d_i)]$$

$$\operatorname{argmin}_{d_i \in \mathcal{C}(q)} [\sqrt{\|q - d_i\|}]$$



Кластеризация

# Демонстрация

# Методы улучшения

- 1) Reranking
- 2) Регенерация запросов
- 3) Гибридные подходы

# Итог

RAG даёт:

Точные ответы основанные на релевантной информации

Экономия. Не требует дообучение модели

Проверяемость ответов

Простая актуализация базы знаний